

Méthodes efficaces d'apprentissage pour l'adaptation des modèles de langue

Alexandre Choplin

Tutrice de stage :

Mme Estelle Zheng

Référente universitaire :

Mme Hee-Soo Choi

Co-tuteur :

M. Christophe Cerisara

Contenu

1. Présentation de l'organisme d'accueil
2. Environnement technique
3. Objectifs du stage
4. Organisation du travail
5. Première partie : exploration et premiers tests
6. Deuxième partie : mathématiques et compréhension fine
7. Troisième partie: Implémentation d'un papier scientifique
8. Conclusion

Présentation de l'organisme d'accueil

Présentation de l'organisme d'accueil

- Le Loria : structure publique
- L'équipe SyNaLP : TAL, LLM, faibles ressources
- Encadrement : Estelle Zheng (doctorante CIFRE)

Environnement technique



Environnement technique

- Matériel : PC perso + Grid5000
- Langages : Python, PyTorch, Transformers
- Outils : Linux, SSH, conda, PEFT, wandb

Objectifs du stage

🎯 Objectifs du stage

- Contexte : C'est quoi un LLM ?
- Problème : adapter les LLM coûte cher (GPU, mémoire)
- But : aider à développer une méthode plus économique
- Mission : Aider à comparer une nouvelle méthode à des approches connues

Organisation du travail

Organisation du travail

- Cadre : autonomie, réunions hebdo, bureau sur site
- **Planning** : formation → expériences → implémentation

Première partie : exploration et premiers tests

Premiers tests et autoformation

- Autoformation :
 - Comprendre le fonctionnement des LLM
 - Comprendre le principe du réentraînement
 - Comment préparer et structurer les données
 - Bases de l'évaluation de modèle
- Objectif : apprendre les outils (Huggingface, Grid5000)

Entraînement et premiers résultats

- Modèle utilisé : Qwen-2.5-0.5B-Instruct
- Tâche : classification logique (MNLI)
- Objectif : comprendre le pipeline d'entraînement
- Méthode :
 - Entraînement itératif : LoRA (PEFT)
 - Analyse des erreurs via matrices de confusion
 - Mesure de l'exactitude (accuracy)
- Résultat : jusqu'à +19 points de gain d'exactitude

⚙️ Problèmes et résultats inattendus

- Difficultés rencontrées :
 - L'apprentissage demande beaucoup d'intuition
 - Problèmes liés aux drivers GPU, versions de CUDA
- Apprentissages :
 - Débogage de code d'entraînement
 - Importance du formatage des données
 - Moins de code, plus de lecture et compréhension fine
- Adaptation :
 - Évaluation personnalisée puis standardisée avec `lm-eval-harness`
 - Analyse fine des erreurs pour guider les itérations

Deuxième partie : mathématiques et compréhension fine

Nouvelle tâche : raisonnement mathématique

- Changement de tâche : résolution d'exercices de maths (GSM8K)
- Méthodologie :
 - Réutilisation de la boucle d'entraînement avec adaptation
 - Modèle utilisé : Qwen-2.5-Math-1.5B-Instruct
 - Évaluation avec `lm-eval-harness`
- Contraintes supplémentaires :
 - Refus d'utiliser certains outils Huggingface
 - Réécriture manuelle des étapes clés (data formatting, training loop)

Comprendre la boucle d'entraînement

- Expérience parallèle : entraînement d'un modèle de vision (CNN sur MNIST)
- Objectif : maîtriser chaque étape du processus
- Étapes de la boucle :
 - Prédictions à partir des images
 - Calcul de la perte (loss)
 - Backpropagation et mise à jour (optimiseur)
- Résultat : 98% d'exactitude



Transposition à un LLM mathématique

- Modèle : Qwen-2.5-Math-1.5B-Instruct
- Jeu de données : GSM8K (problèmes scolaires avec raisonnement)
- Objectifs :
 - Réutiliser la logique de la boucle manuelle sur un modèle texte
 - Vérifier les performances et la stabilité du modèle
- Résultat :
 - 84,8% d'exactitude (vs. 84,4% officiel)

Analyse des longueurs de raisonnements

- **Mesure** : longueur moyenne des raisonnements
- **Objectif** : estimer les coûts en tokens pour des raisonnements CoT
- **Résultats** :
 - Labels d'entraînement : 125,86 tokens (mots)
 - Prédictions du modèle : 218,45 tokens (mots)
- **Interprétation** :
 - Le modèle est plus verbeux que nécessaire
 - Impact potentiel sur coût d'inférence et consommation mémoire

✓ Bilan de l'expérience

- Objectifs atteints :
 - Réutilisation d'une boucle d'entraînement manuelle sur plusieurs tâches
 - Meilleure compréhension du fine-tuning low-level
- Limites identifiées :
 - Gain faible sur un modèle déjà spécialisé
 - Probable chevauchement des données d'entraînement
- Apprentissages :
 - Importance de comprendre les abstractions
 - Nécessité de contrôler les biais et le contenu réel des jeux de données

Troisième partie: Implémentation d'un papier scientifique

✂ Implémentation d'une méthode d'adaptation récente

- Méthode implémentée : Ladder Side Tuning (LST) (2022)
- Objectif : Comprendre la méthode en profondeur en repartant du papier scientifique
- Contexte :
 - Peu ou pas de documentation disponible
 - Code des auteurs inutilisable tel quel
 - Nécessité de reconstituer les étapes à partir de zéro




Structure du Ladder Side Tuning

- Un second réseau latéral est ajouté aux couches clés du modèle principal
- Les poids du modèle principal sont figés, seuls ceux du réseau secondaire sont ajustés
- Objectif : adapter sans altérer le modèle d'origine, avec un coût mémoire réduit
- Expérimentations :
 - Versions compactes du réseau secondaire testées
 - Difficultés sur les calculs internes (matrices non carrées)

Sélection des couches importantes

- Méthode utilisée : Information de Fisher
- Objectif : Identifier les couches clés à conserver pour le réseau secondaire



📈 Résultats obtenus

- Modèle testé avec 10 couches latérales non redimensionnées
- Taux d'exactitude obtenu : 59,94%, identique à LoRA

Step	Epoch	Loss	Accuracy
450	1	0.5273	53.43%
900	1	0.0334	
1350	1	0.3418	
1800	1	0.2070	
2000	1	0.4043	
2250	1	0.1650	
2700	1	0.0315	
3150	1	0.1680	
3600	1	0.3926	
4000	1	0.5430	
4050	1	0.4336	57.410000000000004%
4500	1	0.1108	
4950	1	0.4941	
5400	1	0.2158	
5850	1	0.1172	
6000	1	0.1846	

Step	Epoch	Loss	Accuracy
6300	1	0.3672	59.5%
6750	1	0.4531	
7200	1	0.2334	
7650	1	0.1787	
8000	1	0.5391	
8100	1	0.0491	
8550	1	0.3730	
9000	1	0.4238	
9450	1	0.0767	
9900	1	0.1768	
10000	1	0.1924	59.940000000000005%

Evaluation score of the ladder after fine tuning : 59.940000000000005

✓ Bilan de l'implémentation LST

- Objectifs atteints :
 - Reproduction fonctionnelle d'une méthode de recherche avancée
 - Compréhension détaillée des mécanismes internes d'un LLM
- Limites identifiées :
 - Méthode d'importance des couches partiellement biaisée
 - Résultats comparables à des méthodes plus simples
- Apprentissages :
 - Capacité à reconstruire une méthode à partir d'un article scientifique
 - Connaissances approfondies en structure interne des modèles

Conclusion

Bilan et retour sur le stage

- Acquis techniques
- Autonomie, encadrement
- Apports de la formation et manques éventuellement ressentis.
- Intérêt à renouveler ce type de stage pour l'UFR.

Merci pour votre attention !